

ANALÍTICA DE VENTAS DE VIDEOJUEGOS MEDIANTE DATABRICKS

Darren J. Blackman M. - Universidad Tecnológica de Panamá

Resumen— Este trabajo desarrolla un proceso de analítica de datos de extremo a extremo en Databricks Free Edition con un conjunto histórico de ventas de videojuegos. El flujo integra ingesta, limpieza, análisis exploratorio, Spark SQL, segmentación con K-Means y un dashboard interactivo. De 16,598 registros iniciales se obtuvieron 16,327 registros limpios y 8,820.36 millones de unidades acumuladas. PS2 fue la plataforma líder, Action el género con mayor volumen y 2008 el año de mayor venta. El modelo seleccionó $k = 2$ con un silhouette score de 0.8864, evidenciando una separación clara entre títulos de ventas bajas o moderadas y videojuegos de ventas altas.

Palabras clave— Databricks, PySpark, Spark SQL, K-Means, videojuegos, dashboard.

I. INTRODUCCIÓN

La industria de videojuegos genera información histórica sobre plataformas, géneros, publicadoras y ventas regionales. El objetivo del proyecto es transformar dichos datos en conocimiento útil para identificar patrones de mercado y facilitar decisiones de portafolio, segmentación y análisis temporal.

II. DATOS Y METODOLOGÍA

Se utilizó el archivo vgsales.csv, con variables de identificación, clasificación y ventas en Norteamérica, Europa, Japón, otras regiones y el total global. La metodología se organizó en seis notebooks: ingesta, limpieza, análisis exploratorio, SQL, analítica avanzada y preparación del dashboard. La limpieza eliminó 271 registros sin año, imputó 58 publicadoras faltantes, convirtió tipos de datos, verificó duplicados y generó variables como década y región dominante.

III. ANÁLISIS EXPLORATORIO

La versión limpia contiene 16,327 registros y 8,820.36 millones de unidades acumuladas. Wii Sports lideró los títulos con 82.74 millones; PS2 fue la plataforma principal con 1,233.46 millones; Action encabezó los géneros con 1,722.88 millones; y 2008 registró el máximo anual con 678.90 millones. Norteamérica concentró el mayor volumen regional.

IV. ANALÍTICA AVANZADA

Se aplicó K-Means sobre las ventas regionales transformadas con $\log_{10}$ y estandarizadas. Se compararon valores de k entre 2 y 6 mediante silhouette score; el mejor resultado fue $k = 2$ con 0.8864. El clúster 0 agrupó 15,343 títulos con promedio global de 0.303 millones, mientras el clúster 1 reunió 984 videojuegos con promedio de 4.234 millones y mayor alcance, principalmente en Norteamérica y Europa.

V. DASHBOARD

El dashboard publicado en Databricks presenta dos indicadores, cuatro visualizaciones, un filtro por plataforma, un filtro por rango de años y una interpretación textual. Permite explorar ventas por plataforma, género, videojuego y evolución anual sin modificar el código. Se compartió mediante enlace usando las credenciales del publicador; la plataforma puede solicitar autenticación al espectador.

VI. CONCLUSIONES

El proyecto integró PySpark, Spark SQL, aprendizaje no supervisado y visualización interactiva en un flujo reproducible. Los resultados confirman una alta concentración histórica en ciertos títulos, plataformas y géneros, además de dos segmentos

comerciales claramente diferenciados. El dashboard facilita el análisis para usuarios no técnicos y demuestra cómo reutilizar la base de la Tarea 3 dentro de una solución completa en Databricks.

REFERENCIAS

- [1] Databricks, “Databricks Free Edition,” Databricks Documentation. [Online]. Available: <https://docs.databricks.com/aws/en/getting-started/free-edition>. [Accessed: Jul. 17, 2026].
- [2] Apache Software Foundation, “PySpark API Reference,” Apache Spark Documentation. [Online]. Available: <https://spark.apache.org/docs/latest/api/python/>. [Accessed: Jul. 17, 2026].
- [3] Databricks, “AI/BI Dashboards,” Databricks Documentation. [Online]. Available: <https://docs.databricks.com/aws/en/dashboards/>. [Accessed: Jul. 17, 2026].
- [4] GregorUT, “Video Game Sales,” Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/gregorut/videogamesales>. [Accessed: Jul. 17, 2026].

FIGURAS, TABLAS Y EVIDENCIAS

Indicador	Resultado final
Registros limpios	16,327
Ventas globales	8,820.36 millones
Plataforma líder	PS2 - 1,233.46 millones
Género líder	Action - 1,722.88 millones
Año de mayor venta	2008 - 678.90 millones
Modelo avanzado	K-Means: k = 2; silhouette = 0.8864

Fig. 1. Vista general del dashboard publicado en Databricks.




Fig. 2. Top 10 plataformas por ventas globales.

